Reinforcement learning

Geonhee Lee
gunhee6392@gmail.com

Outline

- Introduction to Reinforcement learning
- Markov Decision Process(MDP)
- Dynamic Programming(DP)
- Monte Carlo Method(MC)
- Temporal Difference Method(TD)
    - SARSA
    - Q-Learning
- Planning and Learning with Tabular Methods
- On-policy Control with with Approximation
- On-policy Prediction with Approximation
- Policy Gradient Method
- Actor Critic Method

Introduction to Reinforcement learn

RL 특성

다른 ML paradigms과의 차이점

- No supervisor, 오직 reward signal.
- Feedback이 즉각적이지 않고 delay 된다.
- Time이 큰 문제가 된다(연속적인, Independent and Identically Distributed(i.i.d, 독립항등분포) data가 아니다).
- Agent의 행동이 agent가 수용하는 연속적인 data에 영향을 준다.

Reward

- **Reward**: scalar feedback signal.
- agent가 step t에서 얼마나 잘 수행하는 지 나타냄.
- agent의 목표는 전체 reward의 합을 최대화하는 것

Sequential Decision Making

- Goal: Total future reward를 최대화하는 action 선택.
- Action들은 long term 결과들을 가질 것.
- Reward는 지연될 것.
- long-term reward를 더 크게 얻기 위해 즉각적인 reward를 희생하는 것이 나을 수도 있음.

History and State

- history: observations, actions, rewards의 연속.
- State: 다음에 어떤 일이 일어날 것인지 결정하기 위해 사용된 정보(다음 수식을 위한 정의로 보임)
- 공식으로는, state는 history의 함수이다.

$$S_t = f(H_t)$$

Information State

- Information state(a.k.a. Markov state)는 history로부터 모든 유용한 정보를 포함한다.
- 정보이론 관점에서의 information state 혹은 Markov state라는 상태가 있다. 데어터 관점에서 history의 유용한 정보들을 포함하고 있는 state를 의미한다.

> Definition
>
> > state S_t는 Markov 이다 if and only if $P[S_{t+1}|S_t] = P[S_{t+1}|S_1, \dots, S_t]$

- 미래는 현재의 과거와 독립적이다.
- State가 주어지면, history는 버려질 수 있다.

Fully Observable Environments

- **Full observability**: agent는 직접적으로 enviroment state를 관찰한다.

$$O_t = S_t^a = S_t^e$$

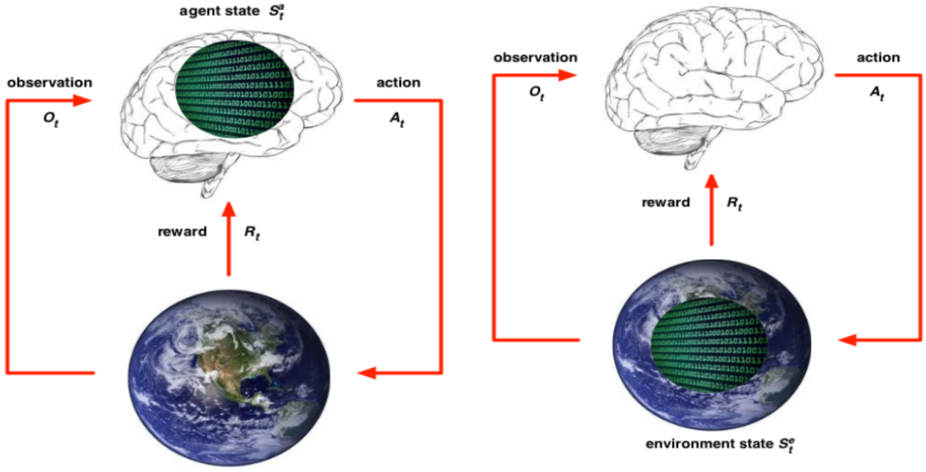

- Agent state = environment state = information state.
- 형식적으로, 이것은 Markov decision precess(MDP).

Partially Observable Environments

- Partial observability: agent는 간접적으로 environment를 관찰.
  - (ex)robot이 카메라를 가지고 절대적인 위치를 알지못하는 것.
  - (ex)포커를 하는 agent는 오직 오픈한 card들만 볼 수 있는 것.
- 여기서는, agent state $\neq$ environment state.
- 형식적으로, 이것을 partially observable Markob decision process(POMDP).
- Agent는 자체 state representation S_t^a을 구성해야만 한다.
  - 다음과 같은 방법으로 만들 수 있다(1. 전체 history 사용, 2. 확률을 사용, 3. RNN 방식 사용).
    - Complete history: $S_t^a = H_t$.
    - **Beliefs** of environment state: $S_t^a = \mathbb{P}\left[S_t^e = s^1\right], \ldots, \mathbb{P}[S_t^e = s^n])$.
    - Recurrent neural network: $S_t^a = \sigma(S_{t-1}^a W_s + O_t W_o)$.

RL Agent의 주요 성분

- **Policy**: agent의 행동 함수.
- **Value function**: 각 state 및/혹은 action이 얼마나 좋은지.
- **Model**: agent's representation of the environment.

Policy

- **Policy**: Agent의 행동.
- State에서 action으로 매핑.
  - Deterministic policy: a = $\pi(s)$.
  - Stochastic policy: $\pi(a|s) = \mathbb{P}[A_t = a|S_t = s]$.

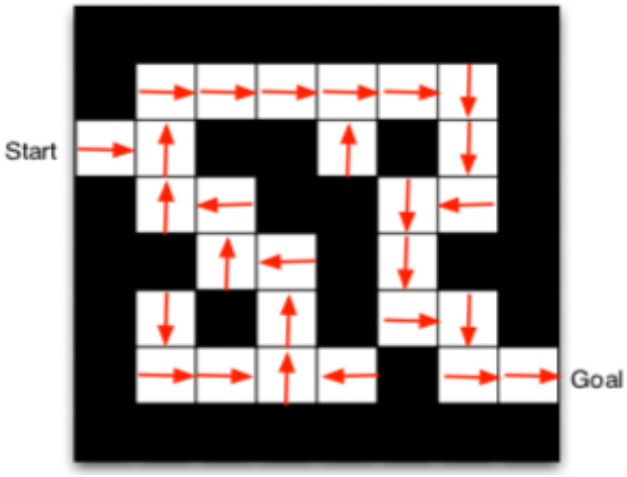

Value function

- **Value function**n: Future reward 예측 값.
- State의 좋은것/나쁜것인지 판단하기 위해 사용.
- Value function을 이용하여 action 선택

$$V_\pi = \mathbb{E}[R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \ldots | S_t = s]$$

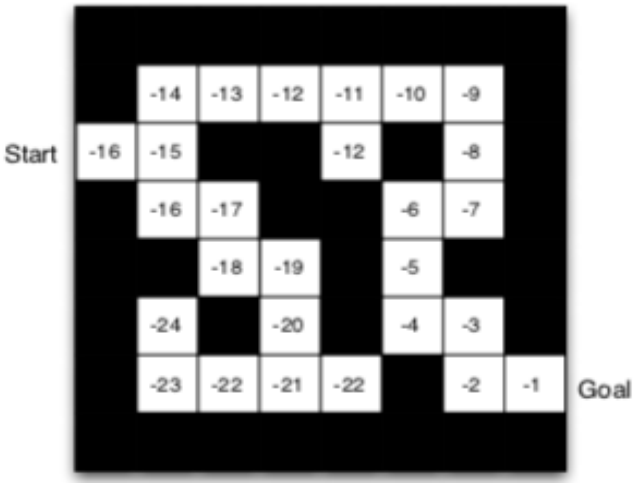

Model

- **Model**: environment에서 다음에 행해질게 무엇인지 예측.
- P: 다음 state를 예측.
- R: 다음(즉각적인) reward를 예측.

$$P^a_{ss'} = \mathbb{P}\left[S_{t+1} = s' | S_t = s, A_t = a\right]$$

$$R^a_s = \mathbb{E}\left[R_{t+1} | S_t = s, A_t = a\right]$$

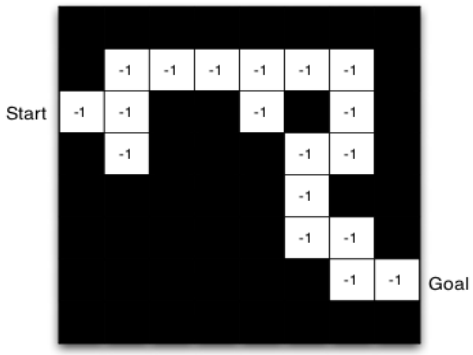

- Agent는 env의 내부 모델을 가지고 있다고 가정.
    - Dynamics: action들이 state를 변화시키는 방법.
    - Rewards: 각 state으로부터 얼마의 reward를 받는 지.
    - Model은 불완전할 것.
- Grid layout은 transition model ($P^a_{ss'}$)를 나타낸다.
- 숫자들은 (모든 행동에 동일한) 각 state s로부터 즉각적인 reward (R^a_s)를 나타낸다.

RL Agent 분류

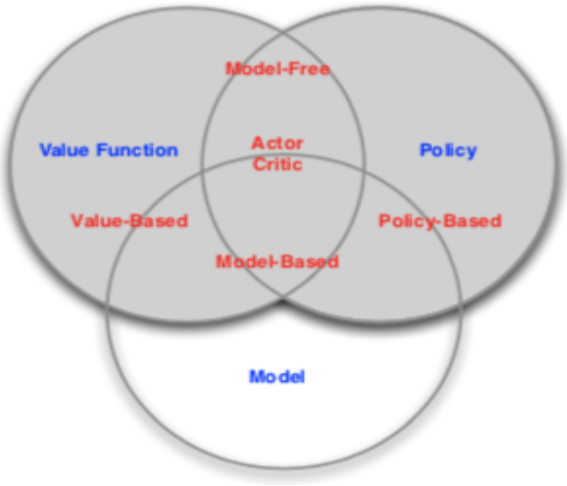

Learnign and Planning

Sequential decision making에서 두 가지 근본적인 문제

- Reinforcement Learning:
    - Env는 초기에 알려져있지 않음.
    - Agent는 Env와 상호작용.
    - Agent는 policy를 향상시킴.
- Planning:
    - Env 모델은 알려져 있음.
    - Agent는 (어떠한 외부 상호작용 없이) 모델과 계산을 수행.
    - Agent는 policy를 향상시킴.
    - a.k.a. deliberation, reasoning, introspection, pondering, thought, search.

Exploration and Exploitation

- RL은 trial-and-error learning과 유사.
- Agent는 good policy를 발견해야만 한다.
    - Env의 경험으로부터
    - 도중에 많은 reward를 잃지 않도록
- **Exploration**은 Env에 대한 더 많은 정보를 찾는다.
- **Exploitation**은 reward를 최대화하기 위해 알려진 정보를 exploit.
- Exploit만큼 explore도 일반적으로 중요하다.

Prediction and Control

- **Prediction**: future를 평가.
  - 주어진 policy를 이용하여 계산 및 평가.
    - (아래그림)Uniform random policy의 value function은 무엇인가?

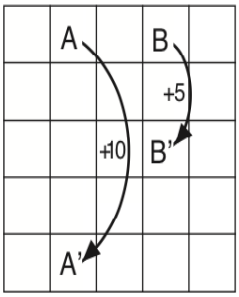

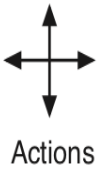

Actions

3.3	8.8	4.4	5.3	1.5
1.5	3.0	2.3	1.9	0.5
0.1	0.7	0.7	0.4	-0.4
-1.0	-0.4	-0.4	-0.6	-1.2
-1.9	-1.3	-1.2	-1.4	-2.0

- **Control**: future를 최적화.
  - best policy를 찾는 것.
    - (아래그림)모든 가능한 정책들에서 optimal value function은 무엇인가?
    - (아래그림)Optimal policy는 무엇인가?

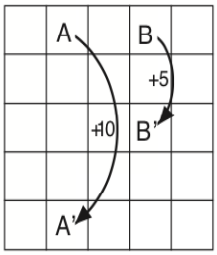

a) gridworld

22.0	24.4	22.0	19.4	17.5
19.8	22.0	19.8	17.8	16.0
17.8	19.8	17.8	16.0	14.4
16.0	17.8	16.0	14.4	13.0
14.4	16.0	14.4	13.0	11.7

b) v_*

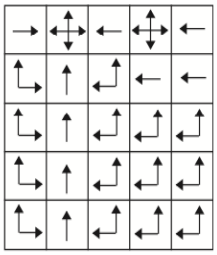

c) π_*

Markov Decision Process(MDP)

Outline

- Markov Processes
- Markob Reward Processes
- Markov Decision Processes
- Extensions to MDPs

Introduction to MDPs

- Markov decision processes(MDP)는 RL에서 Env를 형식적으로 기술.
    - 여기서 Env는 fully observable.
    - i.e., 현재 state는 완전하게 process의 특성을 나타냄.
- 대부분 모든 RL 문제들은 MDPs 로 공식화될 수 있다.
    - Optimal control은 주로 continous MDPs를 다룬다.
    - Partially Observable problem은 MDPs로 변환을 할 수 있다.
    - Bandits은 하나의 state를 가진 MDPs이다.

Markov Property

"미래는 현재에서의 과거와 독립적이다."

> Definition
>
> > state S_t는 ***Markov*** if and only if $\mathbb{P}[S_{t+1}|S_t] = \mathbb{P}[S_{t+1}|S_1,]$

Dynamic Programming(DP)

Monte Carlo Method(MC)

Temporal Difference Method(TD)

Planning and Learning with Tabular Methods

On-policy Control with with Approximation

Policy Gradient Method

Actor Critic Method

Reference

[1] UCL Course on RL

[2] Reinforcement Learning: Tutorial(Seoul National University of Sceience and Technology)

[3] Reinforcement Learning : An Introduction, Sutton

[4] jay.tech.blog

[5] 대손의 스마트 웹